
Lab 5: Reinforcement Learning

1 Markov Reward Process

1.1 Intro

Reward 在一个马尔可夫奖励过程中，从第 t 时刻状态 s_t 开始，直到终止状态时，所有奖励的衰减之和称为回报 G_t 。公式为：

$$\begin{aligned} G_t &:= R_t + \gamma R_{t+1} + \gamma R_{t+2} + \dots \\ &= \sum_{k=0}^{\infty} \gamma^k R_{t+k} \end{aligned}$$




Figure 1: 马尔可夫奖励过程示例

例：从 s_1 开始，选取一条状态序列为 $s_1 \rightarrow s_2 \rightarrow s_3 \rightarrow s_6$, $\gamma = 0.5$, s_1 的回报 G_1 为：

$$\begin{aligned} G_1 &= -1 + 0.5 \times (-2) + 0.5^2 \times (-2) \\ &= -2.5 \end{aligned}$$

1.2 TODO-1

在代码中实现回报公式

2 Markov Decision Process

2.1 Intro

相较于马尔可夫回报过程(MRP)，马尔可夫决策过程(MDP)还多了环境的刺激，我们将环境的刺激称为动作(action)，在马尔可夫回报过程中加入动作(action)就得到了马尔可夫决策过程，由五元组 (S, A, P, r, γ) 构成

- S 是状态的集合
- A 是动作的集合

- γ 是折扣因子
- $r(s, a)$ 是奖励函数，奖励可同时取决于状态 s 和动作 a ，也可只取决于状态 s ，当仅取决于状态 s 时奖励函数退化为 $r(s)$
- $P(s', a)$ 是状态转移函数，表示状态 s 执行动作 a 后到达状态 s' 的概率




Figure 2: 智能体与环境MDP的交互示意图

policy (策略)：智能体根据当前状态从动作集合 A 中选择一个动作的函数称为策略，通常用字母 π 表示，策略 $\pi(a|s) = P(A_t = a|S_t = s)$ 是一个函数，表示在状态 s 时采取动作 a 的概率。策略在每个状态的输出是关于动作的概率分布：如果是确定性的动作，只有一个动作概率为1，其余为0

State value function (状态价值函数) 我们用 $V^\pi(s)$ 表示MDP中基于策略 π 的状态价值函数，定义从状态 s 出发遵循策略 π 能获得的期望回报为

$$V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$$

State-action value function (动作价值函数) 由于动作的存在，马尔可夫决策过程的价值函数在马尔可夫回报过程的价值函数有些差异，定义：

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$$

表示马尔可夫决策过程遵循策略 π 时，对当前的状态 s 执行动作 a 得到的期望回报。状态 s 的价值等于在该状态下基于策略 π 采取所有动作的概率与相应的价值相乘再求和的结果：

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) Q^\pi(s, a)$$

使用策略 π 时，状态 s 下采取动作 a 的价值等于即时奖励加上经过衰减后的所有可能的下一个状态的状态转移概率与相应的价值的乘积：

$$Q^\pi(s, a) = r(s, a) + \gamma \sum_{s' \in S} P(s'|s, a) V^\pi(s')$$

Bellman expectation equation (贝尔曼期望方程) 推导过程：

$$\begin{aligned} V^\pi(s) &= \mathbb{E}_\pi[G_t | S_t = s] \\ &= \mathbb{E}_\pi[R_t + \gamma V^\pi(s_{t+1}) | S_t = s] \\ &= \sum_{a \in A} \pi(a|s) [r(s, a) + \gamma \sum_{s' \in S} P(s'|s, a) V^\pi(s')] \end{aligned}$$

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}_\pi[R_t + \gamma Q^\pi(s_{t+1}, a_{t+1}) | S_t = s, A_t = a] \\ &= r(s, a) + \gamma \sum_{s' \in S} P(s'|s, a) \sum_{a' \in A} \pi(a'|s') Q^\pi(s', a') \end{aligned}$$

2.2 TODO-2

根据实验代码，自行修改状态转移函数以及奖励函数等的参数，体会在马尔可夫决策过程中每个状态价值的变化。




Figure 3: 马尔可夫决策过程一个简单例子

3 Monte Carlo Method

蒙特卡洛方法是一种基于概率统计的数值计算方法。通常使用重复随机抽样，然后运用概率统计方法来从抽样结果中归纳出我们想求的目标的数值估计（例如lab3估计圆周率）。用蒙特卡洛的方法来估计一个策略在一个马尔可夫决策过程中的状态价值函数，一个很直观的想法就是用策略在马尔可夫决策过程上采样多条序列：

$$V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$$

$$\approx \frac{1}{N} \sum_{i=1}^N G_t^{(i)}$$

我们介绍的蒙特卡洛价值估计方法会在该状态每一次出现时计算它的回报。假设我们现在用策略 π 从状态开始采样序列，据此来计算状态价值。我们为每一个状态维护一个计数器和总回报，计算状态价值的具体过程如下所示：

1. 使用策略 π 采样若干条序列：

$$s_0^{(i)} \xrightarrow{a_0^{(i)}} r_0^{(i)}, s_1^{(i)} \xrightarrow{a_1^{(i)}} r_1^{(i)}, s_2^{(i)} \xrightarrow{a_2^{(i)}} \dots \xrightarrow{a_{T-1}^{(i)}} r_{T-1}^{(i)} s_T^{(i)},$$

2. 对每一条序列中的每一时间步 t 的状态 s 进行以下操作：

- 更新状态 s 的计数器 $N(s) \leftarrow N(s) + 1$
- 更新状态 s 的总回报 $M(s) \leftarrow M(s) + G_t$

3. 每一个状态的价值被估计为回报的平均值 $V(s) = M(s)/N(s)$

根据大数定律，当 $N(s) \rightarrow \infty$ ，有 $V(s) \rightarrow V^\pi(s)$ 。计算回报的期望时，除了可以把所有回报加起来除以次数，还有一种增量更新的方法，对每个状态 s 和对应回报 G ，进行如下计算：

- $N(s) \leftarrow N(s) + 1$
- $V(s) \leftarrow V(s) + \frac{G - V(s)}{N(s)}$

3.1 TODO-3

对应上述过程，完成代码填空

Submit

- 2021xxxxxx_xiaoming_lab5.zip (./code ./report.pdf)
- Email xihuaw@ruc.edu.cn, DDL 2022.10.28 20:00